

Основы системного администрирования и сетевых технологий

УРОК №7



# Сортировка файлов с помощью команды sort

Существует большое количество утилит для сортировки, объединения, разбиения и прочей обработки текстовых файлов. Команда sort выполняет сортировку входного потока по ключам сортировки. Она имеет следующий формат: sort [опции] [входные файлы]

Команда выполняет конкатенацию указанных входных файлов, сортирует полученный текст и записывает результат в стандартный выходной поток. Если входные файлы не указаны, то ожидается ввод данных с клавиатуры.

Опции команды sort приведены в табл. 1.



Таблица 1. Опции команды sort

Опция	Описание
-C	Проверка того, отсортирован ли файл; сортировка не производится.
-m	Объединение отсортированных файлов; сортировка не производится.
-u	Удаление повторяющихся строк.
-0	Вывод результата не на экран, а в указанный файл.
-b	Игнорирование начальных пробелов в полях сортировки.
-n	Включение режима числовой сортировки.
-t	Задание разделителей полей.
-r	Сортировка в обратном порядке.
+поз1[,поз2]	Ключом сортировки становится строка, начинающаяся в позиции поз1 и заканчивающаяся перед позицией поз2 (или в конце текущей строки, если поз2 не указан); номера полей и позиции начальных символов отсчитываются от 0.
-к поз1[,поз2]	Ключом сортировки становится строка, начинающаяся в позиции поз1 и заканчивающаяся в позиции поз2 (или в конце текущей строки, если поз2 не указан); номера полей и позиции начальных символов отсчитываются от 1.
-n	Поле с номером п не должно сортироваться.



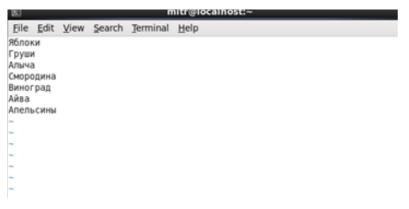


Рисунок 1. Файл a.txt в vi

Чтобы сохранить результаты сортировки используется опция —о и указывается выходной файл. Можно также использовать переадресацию с помощью оператора >, например: sort a.txt > b.txt

Создадим с помощью vi файл a.txt , показанный на рис. 1.vi a.txt

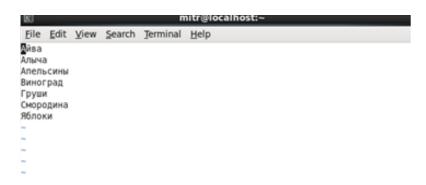


Рисунок 2. Файл b.txt в vi

Выполним команду sort a.txt > b.txt и просмотрим результат ее выполнения с помощью vi. Файл b.txt в vi показан на рис. 2.



<b>E</b>				n	itr@localhost:~
Eile	<u>E</u> dit	<u>V</u> iew	Search	<u>Terminal</u>	<u>H</u> elp
Яблок Груши Алыча Сморо Виног Айва:	:110 :100 дина: рад:1 75	120			
Апель ~	сины	.00			
~					
~					
~					
-					

Рисунок 3. Измененный файл a.txt

Для сортировки по определенным полям используется опция –k. Она указывается в формате:

-k поз1, [поз2...], где поз1 и т.д. – номер позиции (столбца), по которому осуществляется сортировка.

Изменим файл a.txt так, как показано на рис. 3.

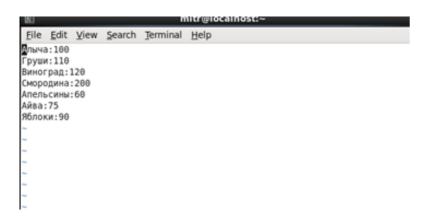


Рисунок 4. Файл, отсортированный по второму полю

Для его сортировки по второму столбцу можно выполнить следующую команду:

sort -t: -k 2 a.txt > c.txt

и просмотрим содержимое c.txt (рис. 4). Опция –t: используется для того, чтобы определить разделитель между полями. По умолчанию разделителем является пробел или символ табуляции.





Обратите внимание на то, что сортировка по второму полю проведена, но числа сравниваются как строки: «100» < «60», поскольку «1» < «6». Теперь с помощью опции –п включим режим числовой сортировки.

sort - n - t: -k 2 a.txt > b.txt

Рисунок 5. Сортировка с числовым режимом

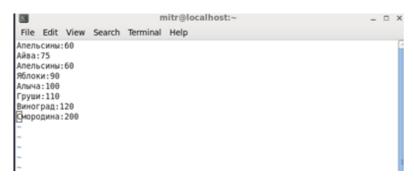


Рисунок 5. Не отсортированный файл

Проверим теперь, является ли файл отсортированным. Сортировать не надо, надо просто проверить. Сделаем это, используя опцию –с:

sort -c -n -t: -k 2 b.txt

Поскольку никаких сообщений в консоль не выведено, то файл отсортирован. Изменим b.txt, нарушив сортировку, как это показано на рис. 6.



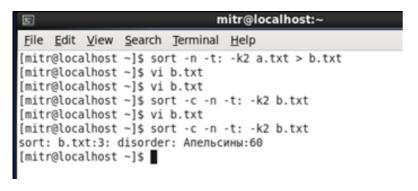


Рисунок 6. Реакция команды на неотсортированный файл



Рисунок 7. Результат выполнения команды

Проверим теперь, является ли файл отсортированным. Сортировать не надо, надо просто проверить. Сделаем это, используя опцию –с:

sort -c -n -t: -k 2 b.txt

Поскольку никаких сообщений в консоль не выведено, то файл отсортирован. Изменим b.txt, нарушив сортировку, как это показано на рис. 6.

Опция -u удаляет из результатов дублирующие записи и выводит только уникальные поля. Результат выполнения команды sort –u –n –t: -k 2 b.txt > c.txt показан на рисунке 7.



### Команда uniq

Опция	Описание
-u	Отображение только не повто-
	ряющихся строк
-d	Отображение одной копии ка-
	ждой повторяющейся строки
-C	Удаление повторяющихся
	строк с выводом перед каждой
	из оставшихся строк числа по-
	вторений
-fn	Игнорировать первые п полей;
	полем считается последова-
	тельность непробельных сим-
	волов, завершающаяся пробе-
	лом или табуляцией

Таблица 2. Опции команды uniq

Команда uniq применяется для удаления идущих подряд повторяющихся строк. Эту команду можно рассматривать как вариант опции – и команды sort. Однако, sort - и позволяет избавиться от всех одинаковых строк в файле, тогда как uniq обнаруживает повторяющиеся строки только тогда, когда они следуют одна за другой.

Формат команды uniq следующий: uniq [Опции] ... [ВХОДНОЙ ФАЙЛ [ВЫХОДНОЙ ФАЙЛ]] В табл. 2 приведены некоторые опции команды uniq.

Применим команду uniq к файлу b.txt, содержимое которого приведено на рис. 5. uniq b.txt

Результат выполнения команды показан на рис. 8.





Применим команду uniq к файлу b.txt, содержимое которого приведено на рис. 5. uniq b.txt

Рисунок 8. Результат выполнения команды

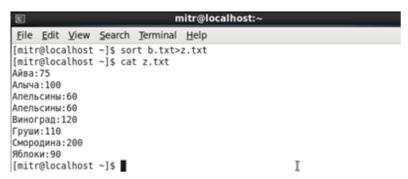


Рисунок 9. Результат сортировки

Поскольку идущих подряд одинаковых строк нет, то вывод команды совпадает с содержимым файла. Отсортируем файл b.txt с помощью команды sort b.txt > z.txt

Результат сортировки показан на рис. 9.

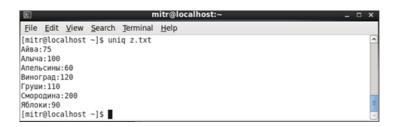


Рисунок 10. Результат выполнения команды

Применим команду uniq z.txt

ко вновь полученному файлу. Теперь в нем есть идущие подряд одинаковые строки. Результат выполнения команды показан на рис. 10.





Рисунок 11. Результат выполнения команды

Воспользуемся ключом –u: uniq -u z.txt Результат выполнения команды показан на рис. 11. Повторяющие идущие подряд строки не выведены.



Рисунок 12. Результат выполнения команды

Воспользуемся ключом –с: uniq -c z.txt Результат выполнения команды показан на рис. 12. Теперь возле каждой из идущих подряд повторяющихся строк указано количество повторений.



## Команда join

Команда join выполняет соединение двух текстовых файлов на основании совпадения указанных полей. Ее действие напоминает операцию JOIN языка SQL. Команда работает следующим образом.

- 1) Каждый из двух входных файлов разбивается на поля, по умолчанию разделителем полей является пробел.
- 2) Из первого файла извлекается первая строка, а из нее указанное поля (по умолчанию первое поле).
- 3) Во втором файле ищется строка, имеющая такое же поле.
- 4) Найденная строка, из которой удаляется найденное поле, присоединяется к исходной строке и результат записывается в выходной поток.
- 5) Пункты 3 и 4 повторяются до тех пор, пока во втором файле есть строки с совпадающим полем.
- 6) Пункты 2 5 повторяются для каждой строки первого файла. Таким образом, в выходной поток по умолчанию попадают только строки, имеющие общие компоненты.

Важно: первый и второй файлы должны быть отсортирован по полям, по которым выполняется соединение.

Синтаксис команды:

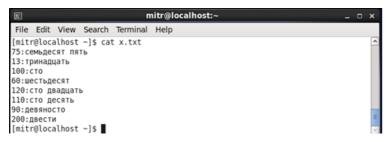
join [опции] файл1 файл2

Наиболее часто используются следующие опции:



Опция	
-a n	Задает включение в выходной поток строк из файла n (n может быть 1 или 2), для которых не найдено ни одного совпадения по указанному полю.
- о формат	Определяет формат выводимой строки. Параметр «формат» представляет собой разделенный запятыми или пробелами список спецификаций, каждая из которых имеет формат номер_файла.поле. По умолчанию используется следующий формат: 1 — поле, по которому производится объединение; 2 — оставшаяся часть первой строки; 3 — оставшаяся часть второй строки.
-1 поле	Объединять строки по указанному полю первого файла (по умолчанию – первое поле)
-2 поле	Объединять строки по указанному полю второго файла (по умолчанию – первое поле)
-t	Задает разделитель полей во входном и выходном потоке





Пусть есть файл z.txt, приведенный на рис. 9. Создадим файл x.txt, приведенный на рис. 13.

Рисунок 13. Файл x.txt



Пусть необходимо выполнить соединение по числовому полю, второму в первом файле и первому во втором файле.

Отсортируем файл x.txt по первому полю с помощью команды sort, как это показано на рис. 14.

Рисунок 14. Отсортированный по первому полю файл x.txt

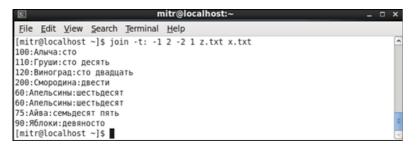


Обратите внимание на то, что сортировка чисел проводится по правилам сортировки строк, поскольку при сортировке не использована опция –п и, следовательно, режим числовой сортировки не включен.

Отсортируем файл z.txt по второму полю, как это показано на рис. 15.

Рисунок 15. Отсортированный файл z.txt





Выполним присоединение файла x.txt к файлу z.txt, как это показано на рис. 16.

Рисунок 16. Присоединение файла x.txt к файлу z.txt



Присоединение произошло. Если необходимо оставить в выводе только второе и третье поле и сохранить результаты в файле, то воспользуемся командой join с ключами, показанными на рис. 17.

Рисунок 17. Присоединение файла с нужными полями

Теперь скопируем в домашний каталог файлы /etc/passwd и /etc/group с помощью команд ср /etc/passwd password.txt ср /etc/group group.txt Содержимое файлов password.txt и group.txt показано на рис. 18 и рис. 19.



```
avahi-autoipd:x:170:170:Avahi IPv4LL Stack:/var/lib/avahi-autoipd:/sbin/nologin
vcsa:x:69:69:virtual console memory owner:/dev:/sbin/nologin
saslauth:x:498:76:Saslauthd user:/var/empty/saslauth:/sbin/nologin
rpcuser:x:29:29:RPC Service User:/var/lib/nfs:/sbin/nologin
nfsnobody:x:65534:65534:Anonymous NFS User:/var/lib/nfs:/sbin/nologin
postfix:x:89:89::/var/spool/postfix:/sbin/nologin
pulse:x:497:495:PulseAudio System Daemon:/var/run/pulse:/sbin/nologin
haldaemon:x:68:68:HAL daemon:/:/sbin/nologin
ntp:x:38:38::/etc/ntp:/sbin/nologin
apache:x:48:48:Apache:/var/www:/sbin/nologin
radvd:x:75:75:radvd user:/:/sbin/nologin
gdm:x:42:42::/var/lib/gdm:/sbin/nologin
gemu:x:107:107:gemu user:/:/sbin/nologin
sshd:x:74:74:Privilege-separated SSH:/var/empty/sshd:/sbin/nologin
tcpdump:x:72:72::/:/sbin/nologin
mitr:x:500:500:mitr:/home/mitr:/bin/bash
[mitr@localhost ~]$ ■
```

Рисунок 18. Содержимое файла password.txt (сокращено)



Рисунок 19. Содержимое файла group.txt (сокращено)

```
File Edit View Search Terminal Help
wbpriv:x:88:
pulse:x:495:
pulse-access:x:494:
fuse:x:493:
haldaemon:x:68:haldaemon
ntp:x:38:
apache:x:48:
radvd:x:75:
gdm:x:42:
kvm:x:36:qemu
qemu:x:107:
sshd:x:74:
slocate:x:21:
tcpdump:x:72:
mitr:x:500:
[mitr@localhost ~]$
```



Соединим эти файлы, чтобы получить в одном файле входное имя пользователя, имя группы (не GID, а имя группы) и домашний каталог пользователя.

В этих файлах есть общее поле – идентификатор группы (GID). В файле password.txt оно находится в четвертом поле, в файле group.txt – в третьем поле. Входное имя пользователя находится в первом поле password.txt, имя группы – в первом поле файла group.txt, домашний каталог – в шестом поле файла password.txt.

Отсортируем password.txt по четвертому полю (рис 20), a group.txt – по третьему, как это показано на рис. 21.

Рисунок 20. Файл password.txt, отсортированный по четвертому полю (сокращено)

```
mitr@localhost:~
 File Edit View Search Terminal Help
[mitr@localhost ~]$ sort -t: -k 4,4 -o password.txt password.txt
[mitr@localhost ~]$ cat password.txt
halt:x:7:0:halt:/sbin:/sbin/halt
operator:x:11:0:operator:/root:/sbin/nologin
root:x:0:0:root:/root:/bin/bash
shutdown:x:6:0:shutdown:/sbin:/sbin/shutdown
sync:x:5:0:sync:/sbin:/bin/sync
bin:x:1:1:bin:/bin:/sbin/nologin
games:x:12:100:games:/usr/games:/sbin/nologin
qemu:x:107:107:qemu user:/:/sbin/nologin
usbmuxd:x:113:113:usbmuxd user:/:/sbin/nologin
mail:x:8:12:mail:/var/spool/mail:/sbin/nologin
uucp:x:10:14:uucp:/var/spool/uucp:/sbin/nologin
oprofile:x:16:16:Special user account to be used by OProfile:/home/oprofile:/sbin/nologin
avahi-autoipd:x:170:170:Avahi IPv4LL Stack:/var/lib/avahi-autoipd:/sbin/nologin
abrt:x:173:173::/etc/abrt:/sbin/nologin
daemon:x:2:2:daemon:/sbin:/sbin/nologin
rpcuser:x:29:29:RPC Service User:/var/lib/nfs:/sbin/nologin
gopher:x:13:30:gopher:/var/gopher:/sbin/nologin
rpc:x:32:32:Rpcbind Daemon:/var/cache/rpcbind:/sbin/nologin
ntp:x:38:38::/etc/ntp:/sbin/nologin
adm:x:3:4:adm:/var/adm:/sbin/nologin
gdm:x:42:42::/var/lib/gdm:/sbin/nologin
apache:x:48:48:Apache:/var/www:/sbin/nologin
```

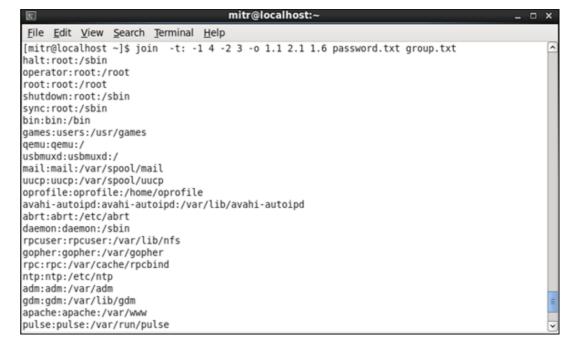


Рисунок 21. Файл group.txt, отсортированный по третьему полю (сокращено)

```
mitr@localhost:~
File Edit View Search Terminal Help
[mitr@localhost ~]$ sort -t: -k 3,3 -o group.txt group.txt
[mitr@localhost ~]$ cat group.txt
root:x:0:
bin:x:1:bin,daemon,mitr
wheel:x:10:
users:x:100:
gemu:x:107:
cdrom:x:11:
usbmuxd:x:113:
mail:x:12:mail,postfix
uucp:x:14:
man:x:15:
stapusr:x:156:
stapsys:x:157:
stapdev:x:158:
oprofile:x:16:
avahi-autoipd:x:170:
abrt:x:173:
dialout:x:18:
floppy:x:19:
daemon:x:2:bin,daemon
games:x:20:
slocate:x:21:
utmp:x:22:
```



Рисунок 22. Соединение файлов password.txt и group.txt по полю GID (сокращено) Теперь соединим файлы password.txt и group.txt по полю GID и выведем необходимые поля с помощью опции –о, как это показано на рис. 22.





#### Команда cut

Опция	Описание
-с список	Определяет, какие симво- лы извлекаются из каждо- го входного файла
-f список	Определяет, какие поля извлекаются из каждого входного файла
-d	Задает разделитель по- лей

Команда cut предназначена для вырезания (выделения) фрагментов строк из текстовых файлов или входного потока. Выделенный текст направляется в выходной поток. Синтаксис команды:

cut OPTION... [FILE]...

Часто используемые опции команды представлены в таблице.

Параметр список в опциях –с и –f представляет собой диапазон символов или полей, разделенных запятыми.

Список может быть описан в одной из следующих форм:

- n в выходной поток включается кажды n-ый символ или поле каждой строки входного файла;
- n- диапазон формируется от n-ого символа до окончания строки;
- n-m диапазон от n-ого символа (или поля) включительно до m-ого символа (или поля) включительно;
- -m диапазон от начала строки до m-ого символа ключительно.

Выделим из файла group.txt третье поле, как это показано на рис. 23.



Рисунок 23. Третье поле файла group.txt

```
### File Edit View Search Terminal Help

[mitr@localhost ~]$ cut -d: -f 3 group.txt

0
1
10
100
107
11
113
12
14
15
156
157
```



# Команда paste

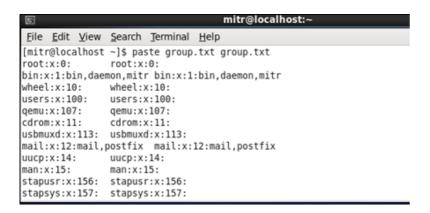
Команда paste объединяет строки с одинаковыми номерами указанных файлов и возвращает объединенные строки в выходной поток.

Синтаксис команды: cut OPTION... [FILE]...

Часто используемые опции команды приведены в таблице.

Опция	Описание
	По умолчанию объединенные строки отделяются символом табуляции. Опция позволяет определить другой разделитель или список разделителей. В случае использования списка, его элементы используются циклически, то есть первый разделитель разделяет первое и второе поле, второй – второе и третье и т.д. Когда символы в списке завершаются, при разделении очередных полей снова используется первый символ.
-S	Определяет режим последовательного слияния строк каждого входного файла по отдельности.
-	Осуществляет выборку строки из входного потока.





На рис. 24 показан результат объединения файла group.txt с самим собой.



На рис. 25 показано использование опции -d.



При использовании опции – s команда paste выполняет слияние всех строк сначала первого файла, а затем второго. Таким образом, формируются столбцы из соответствующих по номерам строк каждого файла. Использование опции – s показано на рис. 27.

```
mitr@localhost:~
_ D X
File Edit View Search Terminal Help
[mitr@localhost ~]$ paste -s a.txt b.txt > f.txt
[mitr@localhost ~]$ cat f.txt
Яблоки:90
               Груши: 110
                               Алыча:100
                                               Смородина:200
                                                               Виноград:120
                                                                               Айва:75 Апельсины:60
Апельсины:60
               Айва:75 Апельсины:60
                                       Яблоки:90
                                                       Алыча:100
                                                                       Груши:110
                                                                                                       Смородина: 200
                                                                                       Виноград: 120
[mitr@localhost ~]$
```

Рисунок 27. Использование опции –s команды paste



# Команда split

Команда split предназначена для разделения больших файлов на более мелкие файлы. Команда split имеет следующий формат:

split [-размер\_выходного\_файла] входной\_файл [префикс] Первый параметр определяет количество строк, на которое необходимо разбить файл.

По умолчанию файл разбивается на фрагменты размером 1000 строк. Если размер разбиваемого файла не кратен 1000 строк, то последний файл будет содержать менее 1000 строк. Например, из файла, содержащего 3100 строк, получатся три файла по 1000 строк в каждом и один файл из 100 строк. Имя каждого созданного файла представляется в формате от префикс[аа] до префикс[zz]. По умолчанию префиксом является символ «х». Таким образом, команда split создает следующую последовательность файлов:

xaa, xab, ... xzy, xzz.

Если расположить файлы в алфавитном порядке и выполнить их последовательную конкатенацию, то получится исходный файл.

